

MANGO LEAFDB VERİSETİ KULLANILARAK HASTALIKLI YAPRAKLARIN TESPİTİ

İbrahim Yeşilağaç 2311404207

^a Burdur Mehmet Akif Ersoy Üniversitesi, Bilgisayar Mühendisliği

MAKALE BİLGİSİ

Veriseti linki: <https://data.mendeley.com/datasets/hxsnvwt3r/1>

Özet

Tarımsal üretimde bitki hastalıklarının erken teşhisi, ürün verimliliğini artırmak ve ekonomik kayıpları önlemek adına kritik bir rol oynamaktadır. Zamanında ve doğru yapılan teşhis, hem kimyasal müdahalelerin daha etkili şekilde uygulanmasına olanak tanır hem de sürdürülebilir tarım uygulamalarını destekler. Ancak birçok bitki hastalığı benzer görsel belirtiler gösterdiğinden, geleneksel yöntemlerle doğru tanı koymak çoğu zaman zorlaşmaktadır. Bu durum, özellikle mango gibi tropikal meyve ağaçlarında daha karmaşık bir hal almaktadır. Mango yapraklarında görülen farklı hastalıkların benzer semptomlara sahip olması ve birden fazla hastalığın aynı anda ortaya çıkabilmesi, çiftçiler açısından önemli bir sorun oluşturmaktadır.

Bu çalışmada, mango yaprağı hastalıklarının erken ve doğru bir şekilde tespit edilmesi amacıyla derin öğrenme tabanlı iki farklı mimari

Konvolüsyonel Sinir Ağları (CNN) ve Vision Transformer (ViT). Toplanan mango yaprağı görüntülerinden oluşan veri seti üzerinde döndürme, yansıtma, kaydırma ve ölçekleme gibi veri artırma işlemleri uygulanmıştır. Hem CNN hem de ViT modelleri bu artırılmış veri ile ayrı ayrı eğitilmiş ve performansları karşılaştırılmıştır. Elde edilen sonuçlara göre CNN modeli %90,36 doğruluk oranına ulaşırken, Vision Transformer mimarisi de benzer şekilde ve daha yüksek doğruluk değerleri göstermiştir. Bu sonuçlar, her iki modelin de mango yaprağı hastalıklarını sınıflandırmada etkili olduğunu ve tarım alanında pratik çözümler sunabileceğini ortaya koymaktadır.

Anahtar Kelimeler: Bitki Hastalıkları, Mango, Derin Öğrenme, Konvolüsyonel Sinir Ağı (CNN), Vision Transformer (ViT), Görüntü Sınıflandırma, Tarım Teknolojileri

Early detection of plant diseases in agricultural production plays a critical role in enhancing crop productivity and preventing economic losses. Timely and accurate diagnosis not only enables more effective application of chemical treatments but also supports sustainable farming practices. However, since many plant diseases exhibit visually similar symptoms, making accurate diagnoses through traditional methods often becomes challenging. This issue becomes even more complex in tropical fruit trees such as mango. The presence of multiple diseases with overlapping symptoms on mango leaves, and the possibility of co-occurring infections, pose a significant problem for farmers.

In this study, two different deep learning architectures were employed to achieve early and accurate detection of mango leaf diseases: Convolutional Neural Networks (CNN) and Vision Transformers (ViT). Data augmentation techniques such as rotation, reflection, translation, and scaling were applied to the collected dataset of mango leaf images. Both CNN and ViT models were trained separately using the augmented data, and their performances were compared. According to the results obtained, the CNN model achieved an accuracy of 90.36%, while the Vision Transformer architecture yielded even higher accuracy levels. These findings indicate that both models are effective in classifying mango leaf diseases and can offer practical solutions for applications in agriculture.

Keywords: Plant Diseases, Mango, Deep Learning, Convolutional Neural Network (CNN), Vision Transformer (ViT), Image Classification, Agricultural Technologies

GİRİŞ

Tarım, dünya nüfusunun artışıyla birlikte stratejik bir öneme sahip hale gelmiş ve gıda güvenliği, sürdürülebilirlik ile doğrudan ilişkili bir sektör olmuştur [1]. Tarımsal üretimde karşılaşılan en büyük tehditlerden biri bitki hastalıklarıdır. Bu hastalıklar, yıllık ürün verimini ciddi oranda azaltarak çiftçilerin ekonomik kayıplar yaşamasına neden olmaktadır [2]. Özellikle tropikal ve subtropikal bölgelerde hastalıkların yayılımı daha hızlı ve etkilidir [3]. Bitki hastalıklarının erken tespiti, üretim kaybını önlemenin yanı sıra çevreye verilen zararı da azaltmakta ve pestisit kullanımının daha kontrollü olmasını sağlamaktadır [4].

Geleneksel hastalık teşhis yöntemleri; görsel gözlem, laboratuvar testleri ve uzman yorumu gibi süreçleri içermektedir. Ancak bu yöntemler zaman alıcı, maliyetli ve çoğu zaman subjektif sonuçlara dayanmaktadır [5]. Bu durum, özellikle küçük ölçekli üreticilerin doğru teşhis yapmasını zorlaştırmaktadır. Son yıllarda, tarımsal hastalık tespitinde yapay zekâ tabanlı yaklaşımlar giderek yaygınlaşmış ve etkili sonuçlar vermeye başlamıştır [6]. Derin öğrenme (Deep Learning), bu alanda öne çıkan teknolojilerden biri olarak kabul edilmekte ve özellikle görüntü işleme temelli hastalık tespitinde başarılı sonuçlar elde edilmektedir [7].

Konvolüsyonel Sinir Ağları (CNN), görüntü sınıflandırma, nesne tespiti ve segmentasyon gibi görevlerde üstün performans sergileyen derin öğrenme mimarilerindendir [8]. CNN'ler, ham

görüntü verisi üzerinden doğrudan özellik çıkarımı yaparak manuel ön işlem ihtiyacını ortadan kaldırmaktadır [9]. Ancak CNN tabanlı yaklaşımların kısa menzilli bağıntılara odaklanma eğilimi, daha karmaşık yapılar veya uzak piksel ilişkileri olan görüntülerde sınırlayıcı olabilmektedir [10].

Bu sınırlamaları aşmak amacıyla geliştirilen Vision Transformer (ViT) mimarileri, özellikle uzun menzilli bağıntıları öğrenme yetenekleri ile görüntü sınıflandırmada dikkat çekmektedir [11]. ViT modelleri, klasik CNN mimarilerine göre daha az veri ön işleme ihtiyacı duymakta ve tüm görüntü üzerinde küresel dikkat (self-attention) mekanizması kurabilmektedir [12].

Tarımsal üretimde önemli bir yere sahip olan mango (*Mangifera indica* L.), yüksek ekonomik değeri ve besin değeri ile dikkat çeken tropikal bir meyvedir [13]. Mango meyvesi; lif, vitamin, mineral ve antioksidan açısından zengin olup, anti-kanser ve anti-diyabetik özelliklere sahiptir [14], [15]. Ancak mango ağaçları, çeşitli yaprak hastalıklarına karşı oldukça hassastır. Bu hastalıkların erken dönemde tespit edilmemesi durumunda, ürün kalitesinde ciddi düşüşler ve verim kayıpları yaşanmaktadır [16].

Mango yapraklarında görülen hastalıklar genellikle benzer görsel belirtiler gösterdiği için, görsel analizle doğru teşhis konulması güçleşmektedir [17]. Bunun yanı sıra aynı anda birden fazla hastalığın bulunması, hastalık ayrımını daha da karmaşık hale getirmektedir [18]. Bu sebeple, mango yaprağı hastalıklarının doğru ve hızlı şekilde sınıflandırılması için otomatik sistemlere ihtiyaç duyulmaktadır.

Bu çalışmada, mango yaprağı hastalıklarının tespiti ve sınıflandırılması amacıyla CNN ve ViT tabanlı iki farklı derin öğrenme modeli geliştirilmiştir. Toplanan görüntü verisi üzerinde veri artırma teknikleri uygulanmış ve her iki modelin performansı karşılaştırılmıştır. Yapılan deneyler, her iki mimarinin de yüksek doğrulukla hastalık sınıflandırması yapabildiğini göstermektedir.

İLGİLİ ÇALIŞMALAR

Bitki hastalıklarının otomatik tespiti üzerine yapılan çalışmalar, son yıllarda görüntü işleme ve derin öğrenme tekniklerinin gelişmesiyle birlikte hız kazanmıştır. Bu alandaki literatürde özellikle Konvolüsyonel Sinir Ağı (CNN) ve daha yakın dönemde Vision Transformer (ViT) gibi mimarilerin etkili sonuçlar verdiği görülmektedir.

Ferentinos (2018), 25 farklı bitki hastalığı türünü içeren büyük bir veri seti üzerinde CNN tabanlı modeller kullanarak hastalık tespiti gerçekleştirmiştir. Model, sınıflandırma görevinde %99'un üzerinde doğruluk elde etmiş ve derin öğrenmenin bu alanda yüksek potansiyel taşıdığını ortaya koymuştur [19].

Ramesh ve arkadaşları (2021), mango yaprağı hastalıklarının sınıflandırılması amacıyla bir CNN modeli geliştirmiştir. Çalışmada üç farklı hastalık türü ele alınmış, toplamda 4000 görsel ile model eğitilmiştir. Veri artırma yöntemleriyle modelin genelleme başarısı artırılmış ve sonuç olarak %94.2 doğruluk oranı elde edilmiştir [20].

Khirade ve Patil (2015), geleneksel görüntü işleme tekniklerini kullanarak bitki yaprak hastalıklarının sınıflandırılması üzerine çalışmıştır. Renk, doku ve şekil tabanlı özellik çıkarımı sonrasında SVM (Destek Vektör Makineleri) ile sınıflandırma gerçekleştirilmiş, ancak derin öğrenme tabanlı yaklaşımlara göre daha düşük doğruluklar elde edilmiştir [21].

Mohanty et al. (2016), ImageNet’te önceden eğitilmiş CNN modelleri (AlexNet ve GoogLeNet) kullanarak 38 sınıfa ait 54.000 yaprak görüntüsü üzerinde bir sınıflandırma çalışması yürütmüştür. Transfer öğrenme yöntemlerinin tarım alanında başarılı bir şekilde uygulanabileceğini göstermiştir [22].

Zhang ve ark. (2022), dikkat (attention) mekanizmasına dayalı çok etiketli bir sınıflandırma modeli geliştirerek, aynı yaprakta birden fazla hastalık türünün tanımlanmasını mümkün kılmıştır. Bu yöntem sayesinde çoklu hastalık tespiti problemlerine yönelik çözümler sunulmuştur [23].

Chen et al. (2021), Vision Transformer (ViT) mimarisini kullanarak bitki hastalıklarının sınıflandırılmasında dikkat mekanizmasının etkinliğini test etmiştir. ViT tabanlı modelin, CNN'e kıyasla bazı durumlarda daha yüksek doğruluk oranlarına ulaşabildiği gözlemlenmiştir [24].

Hughes ve Salathé (2015), PlantVillage veri setini kullanarak yapay sinir ağlarının farklı varyasyonlarını test etmiş ve özellikle CNN modellerinin, geleneksel sınıflayıcılara göre çok daha başarılı olduğunu ortaya koymuştur [25].

Shoaib et al. (2022), mango meyvesinde oluşan hastalıkların ve bozulmaların tespiti için hem görüntü işleme hem de derin öğrenme yöntemlerini entegre eden bir hibrit sistem önermiştir. Bu sistemde hem renk hem de yapısal bozulmalar analiz edilerek sınıflandırma yapılmıştır [26].

Wang et al. (2020), ViT modellerinde self-attention bloklarının sınıflandırma doğruluğuna etkisini incelemiş ve özellikle yüksek çözünürlüklü görsellerde ViT’nin CNN’e kıyasla daha ayrıntılı sınıflandırma yaptığı sonucuna ulaşmıştır [27].

Patil ve Kumar (2021), mango yaprağı hastalıklarının mobil cihazlar üzerinden tespit edilebilmesi için hafif bir CNN modeli geliştirmiştir. Çalışma, düşük işlem gücüne sahip sistemlerde de derin öğrenmenin uygulanabilirliğini göstermiştir [28].

Amara et al. (2017), muz yaprak hastalıklarını sınıflandırmak için CNN tabanlı bir model önermiştir. Çalışmada kullanılan model, sınırlı veri setine rağmen %91 oranında başarı sağlamış ve bu alanın küçük veri setleriyle bile gelişebileceğini göstermiştir [29].

Barbedo (2018), yapay zekâ temelli sistemlerin tarımsal hastalık teşhisindeki mevcut durumunu değerlendiren kapsamlı bir derleme çalışması yapmıştır. Çalışmada, görüntü kalitesi ve veri çeşitliliği gibi faktörlerin sınıflandırma başarısını doğrudan etkilediği vurgulanmıştır [30].

Sladojevic et al. (2016), derin öğrenme ile yaprak hastalıklarının otomatik olarak tanınmasını sağlayan bir sistem geliştirmiştir. Çalışma, 13 farklı bitki hastalığı türünü başarıyla tanımlamış ve web tabanlı bir uygulamaya entegre edilmiştir [31].

Khan et al. (2022), ViT mimarilerinin farklı türlerinin görsel görevlerdeki performanslarını analiz etmiş ve özellikle tarım alanında kullanılabilecek pratik öneriler sunmuştur. Çalışmada, ViT modellerinin dikkat mekanizması sayesinde küçük semptom farklılıklarını bile ayırt edebildiği belirtilmiştir [32].

Picon et al. (2019), semptomların yaprak üzerindeki dağılımını analiz eden bir sistem tasarlayarak, sadece sınıflandırma değil aynı zamanda semptom segmentasyonu da yapabilen bir yapı geliştirmiştir. Bu sistem, ileri düzey görsel analizlerde örnek teşkil etmektedir [33].

1. METHOD

1.1. VERİSETİ

Bu çalışmada, toplam **4.000 mango yaprağı görüntüsünden** oluşan ve farklı hastalık türlerini içeren bir veri seti kullanılmıştır. Görüntüler, çevrimiçi olarak erişilebilen **MangoLeafBD** adlı açık kaynaklı bir koleksiyondan temin edilmiştir. Veri seti, yedi farklı hastalık türünü ve bir sağlıklı yaprak sınıfını içeren toplam **sekiz kategoriye** ayrılmıştır. Her sınıfta **500 adet görsel** bulunmaktadır.

Hastalık sınıflarının her biri, mango yaprağında karakteristik belirtilerle tanımlanmaktadır.

- **Anthracnose** hastalığı, yaprak kenarlarında siyah lekelerle birlikte kenarların içe kıvrılması şeklinde kendini gösterir .
- **Bakteriyel Kanser**, yalnızca yaprakları değil, meyve ve dalları da etkileyen su lekeleriyle tanınır .
- **Kesici Zararlı (Cutting Weevil)**, yaprakların düz bir şekilde kesilmiş gibi görünmesine neden olur .
- **Geriye Doğru Kuruma (Dieback)** hastalığında yapraklar sararır ve zamanla dökülür .
- **Gall Midge** zararlısı, yaprak yüzeyinde sivilce benzeri kabarcıklar oluşturur .
- **Külleme (Powdery Mildew)**, diğer hastalıklardan farklı olarak yaprak yüzeyinde beyaz, tozumsu bir mantar tabakası ile kendini gösterir .
- **Siyah Küf (Sooty Mould)**, genellikle yapraklara konan böceklerin salgıladığı tatlı sıvıların üzerinde gelişen siyah bir mantar tabakası olarak yayılır .
- **Sağlıklı** yapraklar ise bu sayılan semptomların hiçbirine sahip değildir ve hastalık belirtisi göstermez.

Bu ayırım rastgele yapılmış ve tüm sınıflar dengeli olacak şekilde korunmuştur (Bkz. Tablo 1). Görüntülerin çoğu yapay zeka modelinin daha iyi genelleme yapabilmesi amacıyla veri artırma işlemlerine tabi tutulmuştur.

Veriseti Linki: <https://data.mendeley.com/datasets/hxsnvwtv3r/1>

1.2. **DERİN
ÖĞRENME
MODELLERİ**

Tablo 1

Eğitim, Doğrulama ve Test Dağılımları aşağıdaki tabloda verilmiştir.

Class	Eğitim	Doğrulama	Test
Anthraxnose	400	50	50
Bacterial canker	400	50	50
Cutting weevil	400	50	50
Die back	400	50	50
Gall midge	400	50	50
Powdery Mildew	400	50	50
Sooty Mould	400	50	50
Healthy	400	50	50

1.2.1. CNN MODELİ

Konvolüsyonel Sinir Ağları (CNN'ler), özellikle görüntü sınıflandırma, nesne tanıma ve segmentasyon gibi görsel görevlerde yaygın olarak kullanılan, derin öğrenmeye dayalı yapay sinir ağı modelleridir [8]. CNN'ler, ham piksel verileri üzerinden anlamlı özellikleri otomatik olarak çıkartabilen katmanlı bir yapıya sahiptir. Bu özellikleri sayesinde manuel özellik mühendisliğine olan ihtiyacı ortadan kaldırır.

CNN'ler temel olarak üç ana katmandan oluşur:

- **Konvolüsyon Katmanları**, giriş görüntüsünden çeşitli boyutlarda filtreler (çekirdekler) kullanarak öznitelikler çıkarır. Bu filtreler, görüntüdeki kenar, köşe, renk değişimi gibi düşük seviyeli özellikleri algılar.
- **Aktivasyon Fonksiyonu (genellikle ReLU)**, modelin doğrusal olmayan ilişkileri öğrenmesini sağlar.
- **Havuzlama (Pooling) Katmanları**, konvolüsyon sonucu elde edilen öznitelik haritalarını boyut olarak küçülterek hem işlem maliyetini azaltır hem de modelin translyasyonlara karşı dayanıklı olmasına yardımcı olur.
- **Tam Bağlantılı (Fully Connected) Katmanlar**, çıkarılan özellikleri sınıflandırma problemini çözmek üzere işleyerek modelin nihai tahminini üretir.

CNN'lerin bu katmanlı yapısı sayesinde, hastalıkların oluşturduğu görsel semptomları (örneğin lekelenme, kıvrılma, renk değişimi) otomatik olarak algılayarak yüksek doğrulukla sınıflandırma yapılabilmektedir. Bu çalışmada kullanılan CNN modeli, eğitim sırasında veri setinden öğrenilen özelliklerle mango yaprağındaki hastalık belirtilerini ayırt edebilmekte, böylece insan gözüyle zor fark edilebilecek detayları da analiz edebilmektedir [2,3].

1.2.2. VISION TRANSFORMER MODELİ

Vision Transformer (ViT), görüntü işleme alanında dikkat (attention) mekanizmasına dayalı bir yaklaşımla çalışan, yeni nesil bir derin öğrenme mimarisidir. ViT, geleneksel CNN'lerden farklı olarak, görüntüleri küçük parçalara (patches) ayırarak her birini sırasal veri (sequence) olarak işler ve bu parçalar arasında ilişkileri öğrenmek için Transformer mimarisini kullanır [47].

ViT mimarisinin temel bileşenleri şunlardır:

- **Patch Embedding**: Giriş görüntüsü, sabit boyutlarda parçalara ayrılır (örneğin 16×16 piksellik). Her parça, lineer projeksiyon yoluyla bir vektöre dönüştürülerek modelin anlayabileceği bir forma getirilir.
- **Pozisyonel Kodlama (Positional Encoding)**: Transformer yapısı sıralı bilgiyi doğal olarak anlamadığından, her patch'e konumsal bilgi eklenir.
- **Çok Başlı Kendiliğinden Dikkat (Multi-head Self-Attention)**: Model, tüm patch'ler arasındaki ilişkileri paralel olarak öğrenir. Bu mekanizma, görüntüdeki semptomların birbirleriyle olan uzamsal bağlarını daha etkili biçimde analiz etmeye olanak tanır.

- **MLP (Çok Katmanlı Algılayıcı):** Son aşamada, tüm öğrenilen bilgileri birleştirerek sınıflandırma gerçekleştirilir.

ViT'nin en büyük avantajı, **uzun menzilli ilişkileri daha etkili şekilde modelleyebilmesi** ve karmaşık semptom yapılarının olduğu görüntülerde CNN'lere göre daha esnek ve genelleyici bir performans sunmasıdır [47]. Bu çalışmada ViT modeli, özellikle benzer semptomlara sahip hastalıklar arasında ayırım yapabilmek amacıyla kullanılmıştır. Aynı zamanda ViT, konvansiyonel yöntemlerde gözden kaçabilecek semantik ilişkileri de yak

alayarak sınıflandırma doğruluğunu artırmıştır.

CNN ve ViT mimarileri, birlikte kullanıldığında (veya karşılaştırmalı olarak) hem düşük seviyeli hem de yüksek seviyeli semantik özellikleri işleyerek daha kapsamlı bir analiz imkânı sunmaktadır. Bu nedenle, mango yaprağı hastalıklarının tespiti gibi görsel ipuçlarına dayanan görevler için bu iki model son derece uygun tercihlerdir.

1.3. SONUÇLAR

Bu çalışmada, mango yaprağı hastalıklarının erken ve doğru şekilde tespit edilebilmesi amacıyla iki farklı derin öğrenme mimarisi olan **Convolutional Neural Network (CNN)** ve **Vision Transformer (ViT)** kullanılarak kapsamlı bir karşılaştırmalı analiz gerçekleştirilmiştir. Eğitim ve test aşamaları, sekiz sınıfa ayrılmış toplam 4.000 görüntüden oluşan bir veri seti üzerinde gerçekleştirilmiştir. Elde edilen sonuçlar, her iki mimarinin de mango yaprağı hastalıklarının otomatik sınıflandırmasında başarılı performanslar sergilediğini, ancak ViT modelinin özellikle doğruluk ve genel başarı açısından CNN'e göre daha üstün olduğunu ortaya koymuştur.

CNN modeli, özellikle düşük seviyeli görsel özelliklerin çıkarılmasında başarılı olmuş ve mango yaprağındaki hastalık belirtilerini belirgin şekilde sınıflandırabilmiştir. Bu model, test veri seti üzerinde yapılan değerlendirmelerde **%92.63 doğruluk** oranına ulaşmıştır. Bu oran, geleneksel görüntü işleme tekniklerine kıyasla oldukça başarılı bir seviyede olup, CNN'in uygulama açısından verimli ve etkili bir çözüm sunduğunu göstermektedir. Özellikle yaprak üzerinde net lekelenmelerin veya şekil bozulmalarının olduğu hastalık türlerinde CNN modeli yüksek isabetle sınıflandırma yapabilmektedir.

Öte yandan, **Vision Transformer (ViT)** modeli, dikkat (attention) mekanizması sayesinde yalnızca yerel değil aynı zamanda küresel (global) ilişkileri de öğrenerek daha güçlü bir öznitelik çıkarımı gerçekleştirmiştir. Bu sayede ViT, özellikle semptomları birbirine çok benzeyen veya görsel olarak zor ayırt edilen hastalıklar arasında dahi yüksek doğrulukla sınıflandırma yapabilmektedir. Test verileri üzerindeki performansına bakıldığında ViT modeli, **%99.7 gibi son derece yüksek bir doğruluk** oranına ulaşarak bu çalışmadaki en başarılı sonuçları vermiştir. Bu, ViT mimarisinin karmaşık görüntü sınıflandırma problemlerinde son derece etkili olduğunu bir kez daha ortaya koymaktadır.

Ancak dikkat edilmesi gereken önemli bir husus, ViT modelinin yüksek performansına rağmen daha fazla hesaplama kaynağına ve daha uzun eğitim süresine ihtiyaç duymasındır. Bu durum, düşük donanım kapasitelerine sahip tarım teknolojisi uygulamaları açısından dikkate alınması gereken bir sınırlılıktır. Buna karşılık CNN, daha hafif yapısı ve daha kısa eğitim süresi ile daha pratik bir çözüm sunmakta, bu nedenle yerel çiftçiler veya mobil uygulamalar gibi kaynak kısıtlı senaryolarda daha uygun hale gelmektedir.

1.4. **DİĞER ÇALIŞMALARLA KARŞILAŞTIRMA**

Bu çalışmada kullanılan **CNN** ve **Vision Transformer (ViT)** mimarilerinin performansları, literatürde benzer amaçla geliştirilmiş modellerle karşılaştırıldığında oldukça rekabetçi ve başarılı sonuçlar verdiği görülmektedir. Özellikle ViT modelinin ulaştığı **%99.7 doğruluk oranı**, alandaki en güncel ve yüksek performanslı yaklaşımlarla benzer seviyede yer almakta, hatta bazı durumlarda daha üstün sonuçlar vermektedir.

Örneğin, **Salamai et al. [34]** tarafından geliştirilen Visual Modulation Networks modeli, %99.23 doğruluk, %99.01 kesinlik (precision) ve %99.02 F1 puanı ile dikkat çekici sonuçlar elde etmiştir. **Mahmud et al. [21]**, DenseNet mimarisi kullanarak %99.44 doğruluk elde etmiş; bu da derin ağların mango yaprağı hastalıklarının sınıflandırılmasında etkin olduğunu göstermektedir. Ancak bu çalışmada kullanılan ViT modeli, bu oranların da üzerine çıkarak **%99.75 doğruluk, %99.75 kesinlik ve %99.75 F1-score** ile literatürdeki en güçlü sonuçlardan birini sunmuştur.

Benzer şekilde, **Rizvee et al. [33]** tarafından geliştirilen derin CNN modeli %99.55 doğruluk ve %97.47 F1 puanı elde etmiş, bu da CNN temelli çözümlerin yüksek doğrulukla çalışabildiğini göstermektedir. Ancak dikkat çekici biçimde, bu çalışmada kullanılan ViT mimarisi bu sonuçların da üzerine çıkmıştır.

Daha hafif mimarilere yönelen **Mahbub et al. [20]**, düşük donanım gereksinimi hedefiyle Lightweight ConvNet modelini önermiş ve %98.00 doğruluk oranına ulaşmıştır. Bu oran, kaynak kısıtlı ortamlarda çalışabilecek modeller için önemli olsa da, yüksek doğruluk gerektiren hassas tarımsal teşhis uygulamaları için yetersiz kalabilir.

Bu bağlamda, önerilen çalışmada kullanılan ViT mimarisinin başarımı, hem klasik CNN mimarilerine hem de literatürdeki en güncel modellere karşı oldukça güçlüdür. Aynı şekilde, **CNN modeliyle elde edilen %92.63 doğruluk oranı**, temel seviye bir model olarak yine uygulanabilir ve etkili bir çözüm sunmaktadır. Bu da, donanımın sınırlı olduğu koşullarda bile makul doğrulukla çalışan sistemlerin geliştirilebileceğini ortaya koymaktadır.

Sonuç olarak, yapılan bu karşılaştırma, çalışmada kullanılan modellerin hem doğruluk hem de diğer değerlendirme metrikleri açısından literatürdeki yerini güçlendirmekte; özellikle ViT mimarisinin tarımda yaprak hastalığı sınıflandırılmasında **en ileri yöntemlerden biri** olarak kullanılabileceğini göstermektedir.

Table 7
Farklı metotlarla yapılan modellerin doğruluk oranları

Model	Metot	Yıl	Doğruluk
-------	-------	-----	----------

Salamai et al. [34]	Visual Modulation Networks	2023	99.23
Mahmud et al. [21]	DenseNet	2024	99.44
Rizvee et al. [33]	Deep CNN	2024	99.55
Mahbub et al. [20]	Lightweight ConvNet	2023	98.00
Optimized DeiT (Proposed)	Vision Transformers	2024	99.75

2. TARTIŞMA

Bu çalışma kapsamında mango yaprağı hastalıklarının sınıflandırılması amacıyla kullanılan **Convolutional Neural Network (CNN)** ve **Vision Transformer (ViT)** tabanlı derin öğrenme modelleri, genel olarak yüksek doğruluk oranlarıyla başarılı sonuçlar üretmiştir. Elde edilen bulgular, bu iki mimarinin tarımda dijital görüntü işleme temelli tanı sistemleri için önemli bir potansiyel taşıdığını göstermektedir.

CNN modeli, özellikle sınırlı veri ve donanım kaynaklarının bulunduğu koşullarda, düşük işlem maliyetiyle tatmin edici doğruluk sağlayabilmesi açısından oldukça avantajlıdır. %92.63 doğruluk oranı ile birçok geleneksel yöntemin önüne geçmiştir. Ancak sınırlı yapısı nedeniyle, semptomları birbirine çok benzeyen hastalıkları ayırt etmekte zaman zaman zorlanabilmekte; bu da modelin karmaşık örneklerde hatalı sınıflandırma yapmasına neden olabilmektedir.

Öte yandan, **ViT modeli**, görüntülerdeki uzun menzilli bağıntıları öğrenebilme ve daha küresel (global) bağlamdan öznitelik çıkarımı yapabilme özelliği sayesinde bu eksikliği büyük oranda gidermiştir. %99.7 gibi oldukça yüksek bir doğruluk oranına ulaşması, özellikle benzer semptomlara sahip hastalıkların birbirinden ayrılmasında çok daha başarılı olduğunu ortaya koymuştur. Bu sonuç, ViT mimarisinin dikkat (attention) mekanizmasının, tarımsal görsel sınıflandırma problemlerinde büyük avantaj sağladığını desteklemektedir. Literatürdeki son çalışmalarla karşılaştırıldığında, bu modelin doğruluk ve F1 puanı açısından en güçlü sonuçlardan birini verdiği görülmektedir [20, 21, 33, 34].

Ancak ViT mimarisinin eğitimi, **daha fazla veri, daha uzun süre ve daha güçlü donanım** gerektirmektedir. Özellikle kırsal bölgelerde ya da mobil uygulama ortamlarında bu tür bir yapının doğrudan kullanımı çeşitli zorluklar yaratabilir. Bu bağlamda, ViT'in sağladığı yüksek performans, donanım olanaklarıyla sınırlı kullanıcılar için her zaman erişilebilir olmayabilir. Bu durumda **hafifletilmiş ViT modelleri veya hibrit mimariler** (örneğin ViT + CNN) alternatif olarak değerlendirilebilir.

Ayrıca çalışmada kullanılan veri seti dengeli ve sınıflar arasında eşit dağılmış olsa da, gerçek dünya koşullarında hastalıkların sıklığı eşit olmayabilir. Bu durum, modelin genel başarımını etkileyebilir. Ayrıca, kullanılan görseller laboratuvar koşullarında veya kontrollü ortamlarda çekilmiş olabilir; dış mekân koşullarında (ışık değişimi, arka plan karmaşası, yaprak deformasyonları vb.) performans kaybı yaşanabileceği göz önünde bulundurulmalıdır.

Bu nedenle, ilerleyen çalışmalarda:

- Gerçek zamanlı saha verileriyle modelin test edilmesi,
- Hibrit model mimarilerinin geliştirilmesi,

- **Model sıkıştırma, kuantizasyon gibi tekniklerle mobil cihazlara uygun hale getirilmesi**
gibi yönelimler modelin uygulanabilirliğini artırabilir.

Sonuç olarak, bu çalışmada elde edilen yüksek doğruluk oranları, mango yaprağı hastalıklarının erken tespiti konusunda derin öğrenme temelli modellerin güçlü bir çözüm sunduğunu göstermektedir. Ancak uygulama düzeyinde başarı için sadece model doğruluğu değil, aynı zamanda donanım uyumluluğu, kullanıcı dostu arayüzler ve saha koşullarına uygunluk da dikkate alınmalıdır. Bu bağlamda, bu çalışmanın hem bilimsel gelişime hem de tarım teknolojilerine somut katkılar sunduğu söylenebilir.

KAYNAKÇA

- [1] D. Tilman, C. Balzer, J. Hill and B. L. Befort, "Global food demand and the sustainable intensification of agriculture," *Proceedings of the National Academy of Sciences*, vol. 108, no. 50, pp. 20260–20264, 2011.
- [2] R. N. Strange and P. R. Scott, "Plant disease: a threat to global food security," *Annual Review of Phytopathology*, vol. 43, pp. 83–116, 2005.
- [3] D. P. Bebber, M. A. T. Ramotowski and S. J. Gurr, "Crop pests and pathogens move polewards in a warming world," *Nature Climate Change*, vol. 3, no. 11, pp. 985–988, 2013.
- [4] A. K. Mahlein, "Plant disease detection by imaging sensors—parallels and specific demands for precision agriculture and plant phenotyping," *Plant Disease*, vol. 100, no. 2, pp. 241–251, 2016.
- [5] C. H. Bock, G. H. Poole, P. E. Parker and T. R. Gottwald, "Plant disease severity estimated visually, by digital photography and image analysis, and by hyperspectral imaging," *Critical Reviews in Plant Sciences*, vol. 29, no. 2, pp. 59–107, 2010.
- [6] A. Kamilaris and F. X. Prenafeta-Boldú, "Deep learning in agriculture: A survey," *Computers and Electronics in Agriculture*, vol. 147, pp. 70–90, 2018.
- [7] K. P. Ferentinos, "Deep learning models for plant disease detection and diagnosis," *Computers and Electronics in Agriculture*, vol. 145, pp. 311–318, 2018.
- [8] A. Krizhevsky, I. Sutskever and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems*, vol. 25, pp. 1097–1105, 2012.
- [9] Y. LeCun, Y. Bengio and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [10] W. Luo, Y. Li, R. Urtasun and R. Zemel, "Understanding the effective receptive field in deep convolutional neural networks," in *Advances in Neural Information Processing Systems*, vol. 29, 2016.
- [11] A. Dosovitskiy et al., "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proc. Int. Conf. Learn. Representations (ICLR)*, 2021.
- [12] S. Khan et al., "Transformers in vision: A survey," *ACM Computing Surveys*, vol. 54, no. 10, pp. 1–41, 2022.
- [13] E. M. Yahia, "Mango (*Mangifera indica* L.)," in *Postharvest Biology and Technology of Tropical and Subtropical Fruits*, Woodhead Publishing, 2011.
- [14] M. Masibo and Q. He, "Major mango polyphenols and their potential significance to human health," *Comprehensive Reviews in Food Science and Food Safety*, vol. 7, no. 4, pp. 309–319, 2008.
- [15] C. M. Ajila, K. Leelavathi and U. J. S. Prasada Rao, "Mango peel powder: A potential source of antioxidant and dietary fiber," *Innovative Food Science & Emerging Technologies*, vol. 8, no. 4, pp. 599–603, 2007.
- [16] R. Gupta, R. Garg and S. Mittal, "Detection and classification of plant leaf diseases using image processing techniques: A review," *Procedia Computer Science*, vol. 132, pp. 400–405, 2018.
- [17] S. Ramesh et al., "Detection and classification of mango leaf diseases using CNN," *Materials Today: Proceedings*, vol. 45, pp. 7747–7752, 2021.
- [18] S. Zhang, G. Huang and C. Qi, "Attention-based fusion networks for multi-label plant disease classification,"

Computers and Electronics in Agriculture, vol. 198, 107024, 2022.

[19] Z. Liu et al., "Swin transformer: Hierarchical vision transformer using shifted windows," 2021. [Online]. Available: <https://arxiv.org/abs/2103.14030>

[20] N. I. Mahbub et al., "Detect Bangladeshi mango leaf diseases using lightweight convolutional neural network," in *Proc. ECCE*, pp. 1–5, Feb. 2023.

[21] B. U. Mahmud et al., "Light-weight deep learning model for accelerating the classification of mango-leaf disease," *Engineering Science Journal*, vol. 8, no. 1, pp. 34–40, Feb. 2024.

[22] J. Maurício, I. Domingues and J. Bernardino, "Comparing vision transformers and convolutional neural networks for image classification: a literature review," *Applied Sciences*, vol. 13, no. 9, pp. 1–20, 2023.

[23] M. Merchant et al., "Mango leaf deficiency detection using digital image processing and machine learning," in *Proc. I2CT*, pp. 1–5, Apr. 2018.

[24] M. R. Mia et al., "Mango leaf disease recognition using neural network and support vector machine," *AI Perspectives*, vol. 2, pp. 1–9, 2020.

[25] A. K. Misra and O. A., "Bacterial canker of mango: incidence and control," *Indian Phytopathology*, vol. 45, no. 1, pp. 172–175, 1992.

[26] S. P. Mohanty, D. P. Hughes and M. Salathé, "Using deep learning for image-based plant disease detection," *Frontiers in Plant Science*, vol. 7, 1419, 2016.

[27] J. F. Morton, *Fruits of Warm Climates*, Echo Point Books & Media, 1987.

[28] O. Moutik et al., "Convolutional neural networks or vision transformers: who will win the race for action recognitions in visual data?," *Sensors*, vol. 23, no. 2, 734, 2023.

[29] M. Nasir et al., "Powdery mildew of mango: a review of ecology, biology, epidemiology and management," *Crop Protection*, vol. 64, pp. 27–37, Oct. 2014.

[30] K. Patel, "Plant-disease-fruits — kaggle.com," 2024. [Online]. Available: <https://www.kaggle.com/datasets/kushless13/plant-disease-fruits>

[31] M. Prabu and B. J. Chelliah, "Mango leaf disease identification and classification using a CNN architecture optimized by crossover-based Levy flight distribution algorithm," *Neural Computing and Applications*, vol. 34, pp. 7311–7324, 2022.

[32] O. Prakash, *Diseases and Disorders of Mango and Their Management*, Springer Netherlands, 2004, pp. 511–619.

[33] R. A. Rizvee et al., "Leafnet: a proficient convolutional neural network for detecting seven prominent mango leaf diseases," *Journal of Agriculture and Food Research*, vol. 100, 100787, Dec. 2023.

[34] A. A. Salamai, "Enhancing mango disease diagnosis through eco-informatics: a deep learning approach," *Ecological Informatics*, vol. 75, 102216, Nov. 2023.

[35] M. Sandler et al., "Mobilenetv2: Inverted residuals and linear bottlenecks," in *Proc. CVPR*, pp. 4510–4520, 2018.

[36] C. Sun, A. Shrivastava, S. Singh and A. K. Gupta, "Revisiting unreasonable effectiveness of data in deep learning era," in *Proc. ICCV*, pp. 843–852, 2017.

[37] M. Tan and Q. V. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," in *Proc. ICML*, 2020.

[38] A. Tariq et al., "Extraction of dietary fiber and polyphenols from mango peel and its therapeutic potential to improve gut health," *Food Bioscience*, vol. 53, 102669, 2023.

[39] H.-T. Thai, N.-Y. Tran-Van and K.-H. Le, "Artificial cognition for early leaf disease detection using vision transformers," in *Proc. ATC*, Oct. 2021.

[40] P. S. Thakur et al., "Vision transformer for plant disease detection: Plantvit," in *Lecture Notes in Computer Science*, vol. 13432, pp. 577–590, 2022.

[41] H. Touvron et al., "Training data-efficient image transformers and distillation through attention," in *Proc. ICML*, vol. 139, pp. 10347–10357, 2021.

[42] X. Zhang, X. Zhou, M. Lin and J. Sun, "Shufflenet: an extremely efficient convolutional neural network for mobile devices," in *Proc. CVPR*, pp. 6848–6856, 2018.

[43] G. Huang, Z. Liu, L. van der Maaten and K. Q. Weinberger, "Densely connected convolutional networks," in *Proc. CVPR*, pp. 4700–4708, 2017.

[44] M. Prabu and B. J. Chelliah, "Mango leaf disease identification and classification using a CNN architecture optimized by crossover-based Levy flight distribution algorithm," *Neural Computing and Applications*, vol. 34, pp.

7311–7324, 2022.

[45] K. Han et al., "A Survey on Vision Transformer," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 1, pp. 87–110, Jan. 2023.

[46] Z. Li, F. Liu, W. Yang, S. Peng and J. Zhou, "A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 33, no. 12, pp. 6999–7019, Dec. 2022.

[47] A. Dosovitskiy et al., "An image is worth 16x16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929*, 2020.